ACT

Action Chunking Transformer

로봇동작 생성 프레임워크 알고리즘

ACT 알고리즘 핵심구성

CVAE &Transformer

유연성과 적응성

Action Chunking

미래 동작 뭉치 생성

Temporal Ensembling

연속성 및 정밀제어

CVAE : CONDITIONAL VARIATIONAL AUTOENCODER

사용자가 원하는 특성을 가진 데이터를 선택적으로 생성할 수 있는 생성모델

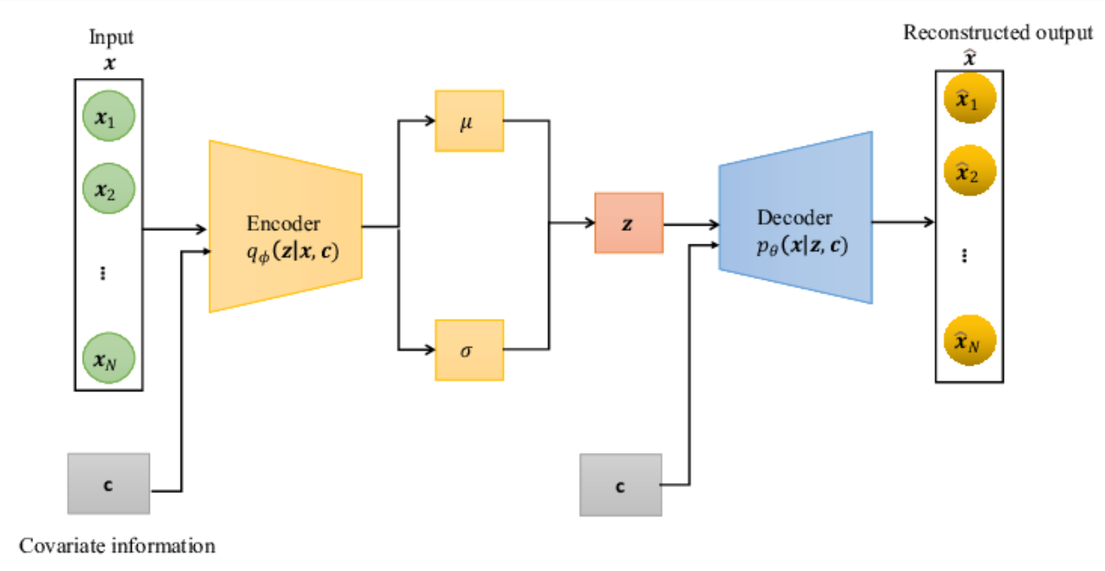

$$\mathcal{L}_{CVAE}(\phi, \theta; x, c) = -KL(q_\phi(z|x, c)||p_\theta(z|c)) + \mathbb{E}_{q_\phi(z|x,c)}[\log p_\theta(x|z, c)]$$

1.CVAE Encoder

- 입력데이터 x와 조건 c를 함께 입력 받아 잠재변수 z의 분포를 학습
- 조건부 확률 분포 파라미터 사용

1.CVAE Decoder

- 잠재변수 z와 조건 c를 결합하여 새로운 데이터 생성

1.목적함수

- CVAE의 학습은 ELBO(Evidence Lower Bound)를 최대화하는 방향으로 진행

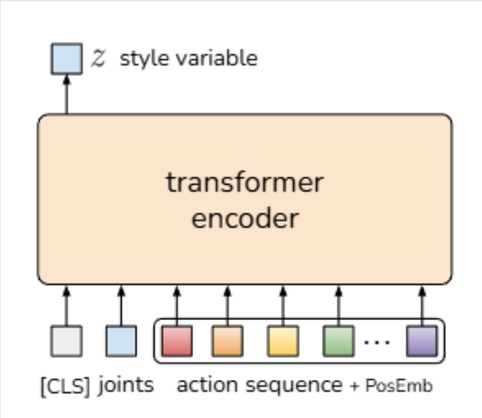

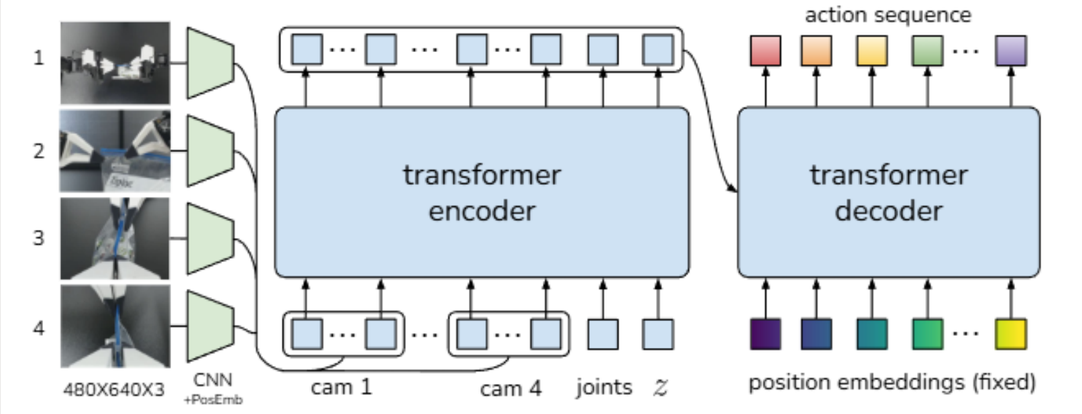

CVAE Encoder

- 로봇의 관절값과 사람이 시연한 미래동작 시퀀스를 입력으로 받음
- 복잡한 동작데이터를 분석하여 그 특징을 스타일 변수라는 고차원 벡터값으로 압축

확률분포학습

- 평균과 분산을 가진 확률 분포형태로 학습하여 비슷한 상황에서 발생할 수 있는 다양한 움직임의 가능성을 모두 포함

CVAE Decoder

- transformer encoder/decoder 구조로 이루어져 있으며 학습된 정보를 바탕으로 현재상황에 맞는 동작을 생성
- 입력 요소 : 스타일변수(z), 현재카메라 영상, 현재 관절값
- 최종 출력 수행할 동작뭉치(Action Chunk) 생성

핵심 이점

확률적 접근을 통해 예측불가능한 상황에서도 자연스럽고 가변적인 동작생성이 가능하여 로봇제어 측면에서 유연성과 적응성을 확보

트랜스포머란?

- 정보를 압축하는 인코더와 정보를 풀어내어 결과를 생성하는 디코더로 구성
- 데이터 순서에 의존하지 않고 전체문맥을 한번에 파악하는 Self-Attention 매커니즘과 병렬처리 능력이 핵심

인코더

- 카메라 영상정보, 로봇의 관절 상태, 스타일 변수 z 사이의 관계를 학습하여 상황정보를 압축

디코더

- 디코더는 크로스 어텐션 매커니즘을 통해 인코더가 제공한 상황정보를 참조하여 로봇팔의 목표관절값을 하나하나 계산

Action Chunking 출력

- 단일 동작이 아닌 수십단계의 연속된 동작 시퀀스를 한번에 출력

ACTION CHUNk

- 한번의 관찰을 통해 미래에 수행할 k 개의 동작 시퀀스를 하나의 뭉치로 한꺼번에 생성
- 복리에러 방지 : 작업전체의 예측 횟수를 줄여주어 에러가 쌓이는 현상을 막아줌
- 비정형적 동작 처리 : 부자연스러운 동작을 Action Chunk 안에 포함시켜 학습하기 때문에 복잡한 동작 패턴을 자연스럽게 수행가능

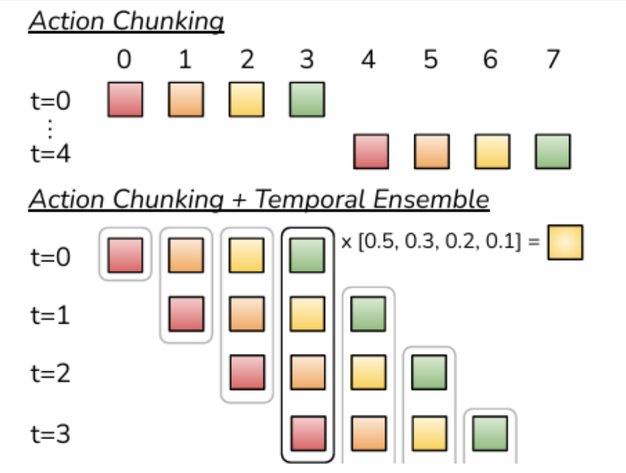

TEMPROAL ENSEMNLING

- 연속적 예측 : 동작뭉치를 단순히 이어붙일 때 발생하는 연결부의 불연속성을 해결하기 위해 매 스텝마다 새로운 동작 시퀀스를 재예측
- 중첩 및 가중 평균 : 중첩된 구간에 대해 지수이동평균과 같은 가중치를 적용하여 부드러운 움직임 구현
- 제어 안정성 확보 : 개별 예측에서 발생할 수 있는 노이즈를 상쇄하고 급격한 움직임 변화를 방지

EXPERIMENT RESULTS

	Cube Transfer (sim)			**Bimanual Insertion** (sim)			**Slide Ziploc** (real)			**Slot Battery** (real)		
	Touched	Lifted	Transfer	Grasp	Contact	Insert	Grasp	Pinch	Open	Grasp	Place	Insert
BC-ConvMLP	34 | 3	17 | 1	1 | 0	5 | 0	1 | 0	1 | 0	0	0	0	0	0	0
BeT	60 | 16	51 | 13	27 | 1	21 | 0	4 | 0	3 | 0	8	0	0	4	0	0
RT-1	44 | 4	33 | 2	2 | 0	2 | 0	0 | 0	1 | 0	4	0	0	4	0	0
VINN	13 | 17	9 | 11	3 | 0	6 | 0	1 | 0	1 | 0	28	0	0	20	0	0
ACT (Ours)	**97 | 82**	**90 | 60**	**86 | 50**	**93 | 76**	**90 | 66**	**32 | 20**	**92**	**96**	**88**	**100**	**100**	**96**

TABLE I: Success rate (%) for 2 simulated and 2 real-world tasks, comparing our method with 4 baselines. For the two simulated tasks, we report [training with scripted data | training with human data], with 3 seeds and 50 policy evaluations each. For the real-world tasks, we report training with human data, with 1 seed and 25 evaluations. Overall, ACT significantly outperforms previous methods.

	Open Cup (real)			**Thread Velcro** (real)			**Prep Tape** (real)				**Put On Shoe** (real)			
	Tip Over	Grasp	Open Lid	Lift	Grasp	Insert	Grasp	Cut	Handover	Hang	Lift	Insert	Support	Secure
BeT	12	0	0	24	0	0	8	0	0	0	12	0	0	0
ACT (Ours)	**100**	**96**	**84**	**92**	**40**	**20**	**96**	**92**	**72**	**64**	**100**	**92**	**92**	**92**

TABLE II: Success rate (%) for the remaining 3 real-world tasks. We only compare with the best performing baseline BeT.

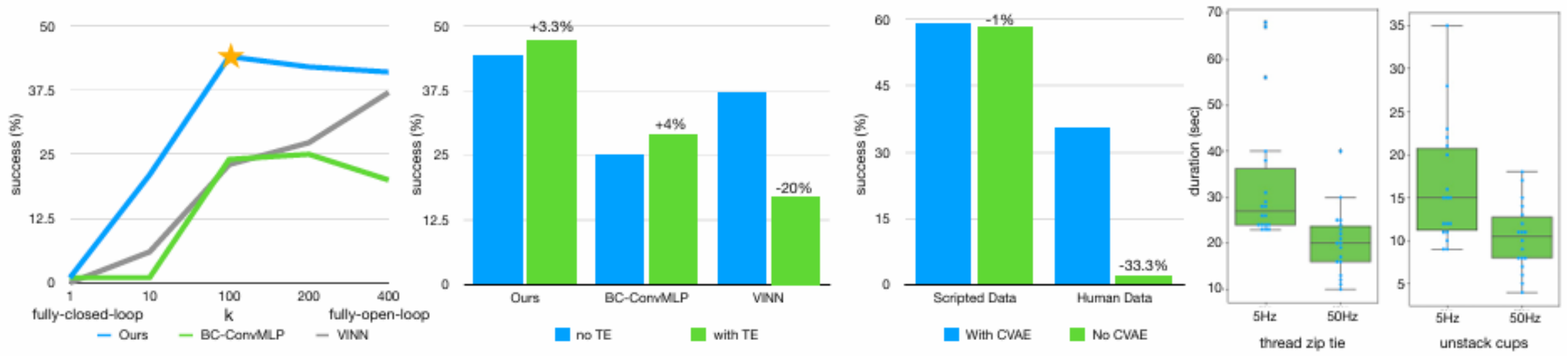

(a) (b) (c) (d)